Московский городской педагогический университет

Платформы Data Engineering '25

Лабораторная работа 2.1. Построение аналитических витрин и внедрение продвинутых dbt-концепций

Выполнил: Ежергин С.С.
учебная группа - 251м

Проверил: доцент департамента информатики,
управления и технологий
Босенко Т.М.

Москва - 2025

Архитектура проекта

Проект реализует многоуровневую архитектуру DWH с использованием dbt:

- Staging-слой - очистка и подготовка исходных данных
- Intermediate-слой - денормализованные модели с инкапсулированной бизнес-логикой
- Marts-слой - специализированные аналитические витрины для бизнес-пользователей
- Snapshots - отслеживание исторических изменений данных

Скриншот графа зависимостей

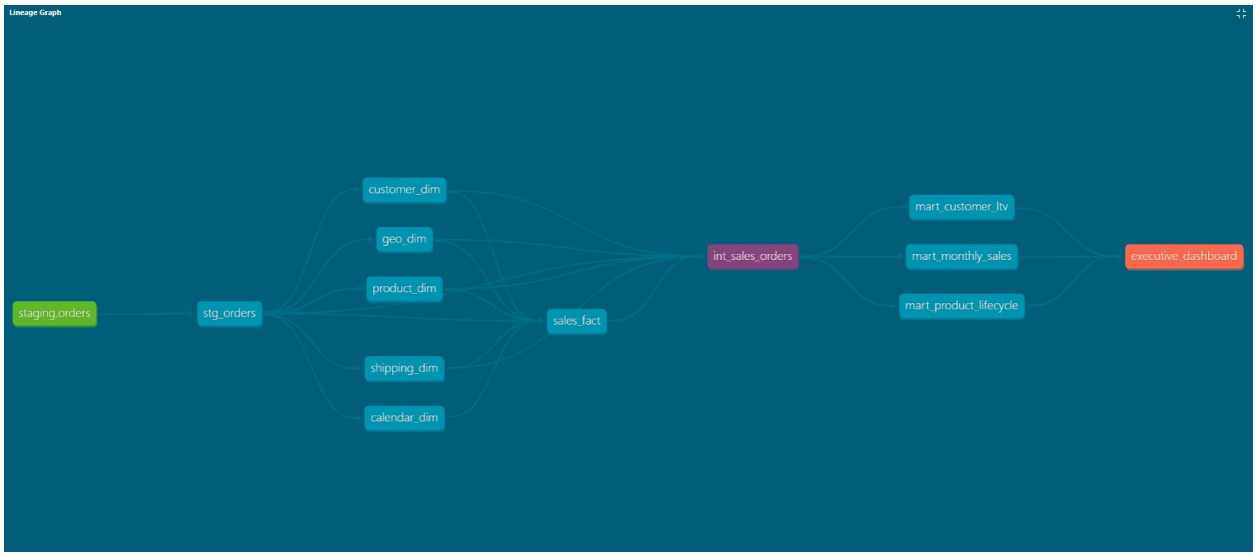

Промежуточная модель (int_sales_orders)

- Создана в папке: models/intermediate/
- Материализована как: view
- В схеме: dw_intermediate
- Содержит: денормализованные данные (объединение фактов + измерений)

Витрины используют промежуточную модель

- mart_monthly_sales → {{ ref('int_sales_orders') }}
- mart_customer_ltv → {{ ref('int_sales_orders') }}
- mart_product_lifecycle → {{ ref('int_sales_orders') }}

Ключевые фрагменты кода

1. Промежуточная модель int_sales_orders.sql

```
{{ config(materialized='view') }}

SELECT
    -- Ключи
    f.order_id,
    -- Измерения из customer_dim
    c.customer_id,
    c.customer_name,
    c.segment as customer_segment,
    -- Измерения из product_dim
    p.product_id,
    p.product_name,
    p.category,
    p.subcategory,
    -- Измерения из geo_dim
    g.city,
    g.state,
    g.region,
    -- Измерения из shipping_dim
    s.ship_mode,
    -- Даты
    o.order_date,
    o.ship_date,
    -- Метрики из sales_fact
    f.sales,
    f.profit,
    f.quantity,
    f.discount
```

```
FROM {{ ref('sales_fact') }} AS f
LEFT JOIN {{ ref('stg_orders') }} AS o ON f.order_id = o.order_id
LEFT JOIN {{ ref('customer_dim') }} AS c ON f.customer_id_key = c.customer_id_key
LEFT JOIN {{ ref('product_dim') }} AS p ON f.product_id_key = p.product_id_key
LEFT JOIN {{ ref('shipping_dim') }} AS s ON f.shipping_id = s.shipping_id
LEFT JOIN {{ ref('geo_dim') }} AS g ON f.geo_id = g.geo_id
```

2. Индивидуальная mart-модель mart_product_lifecycle.sql

```
{{ config(materialized='table') }}

SELECT
    product_id,
    product_name,
    category,
    subcategory,
    MIN(order_date) as first_sale_date,
    MAX(order_date) as last_sale_date,
    (MAX(order_date) - MIN(order_date)) as days_between_sales,
    COUNT(DISTINCT order_id) as total_orders,
    SUM(quantity) as total_quantity_sold,
    SUM(sales) as total_sales
FROM {{ ref('int_sales_orders') }}
GROUP BY product_id, product_name, category, subcategory
ORDER BY days_between_sales DESC
```

3. Кастомный тест test_is_positive.sql

```
{% test is_positive(model, column_name) %}
SELECT *
```

```
FROM {{ model }}
WHERE {{ column_name }} < 0
{% endtest %}
```

4. Применение кастомного теста в schema.yml

```
# models/marts/schema.yml
- name: mart_product_lifecycle
  description: "Анализ жизненного цикла продуктов"
  columns:
    - name: total_quantity_sold
      tests:
        - not_null
        - is_positive
    - name: total_sales
      tests:
        - not_null
        - is_positive
    - name: days_between_sales
      tests:
        - not_null
        - is_positive
```

5. Снимок данных snapshot_product_dim.sql

```
{% snapshot snapshot_product_dim %}
{{
    config(
        target_schema='dw_snapshots',
        strategy='check',
        unique_key='product_id_key',
        check_cols=['category', 'subcategory'],
```

```
    )
}}
SELECT product_id_key, product_id, category, subcategory
FROM {{ ref('product_dim') }}
{% endsnapshot %}
```

6. models\marts\exposures.yml:

```
version: 2


exposures:
  - name: executive_dashboard
    type: dashboard
    maturity: high
    owner:
      name: "Sales Department"
      email: "sales@superstore.com"
    depends_on:
      - ref('mart_monthly_sales')
      - ref('mart_customer_ltv')
      - ref('mart_product_lifecycle')
```

Результаты

Скриншот выполнения dbt run

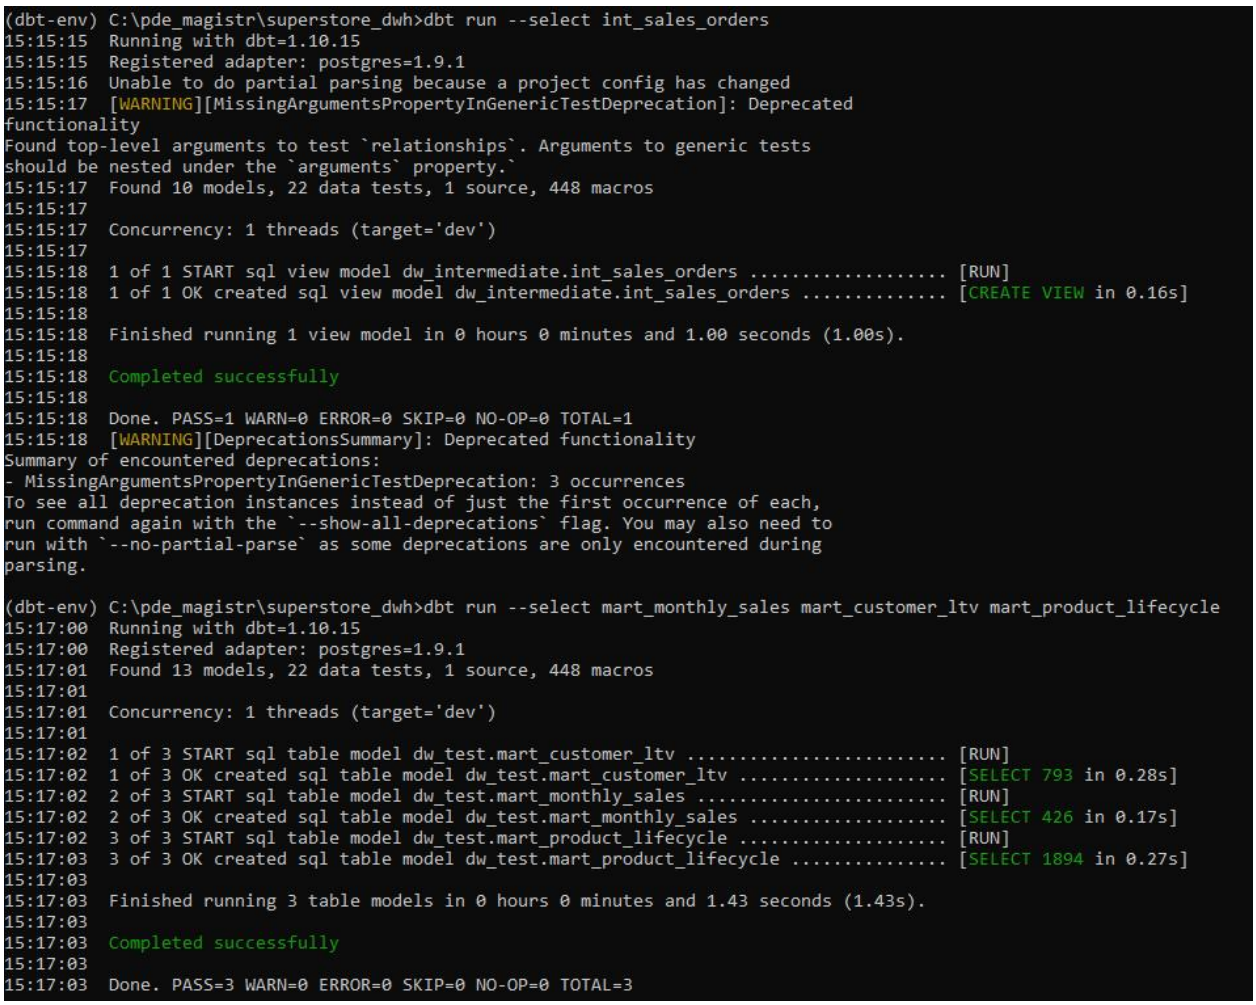

Скриншот выполнения dbt test

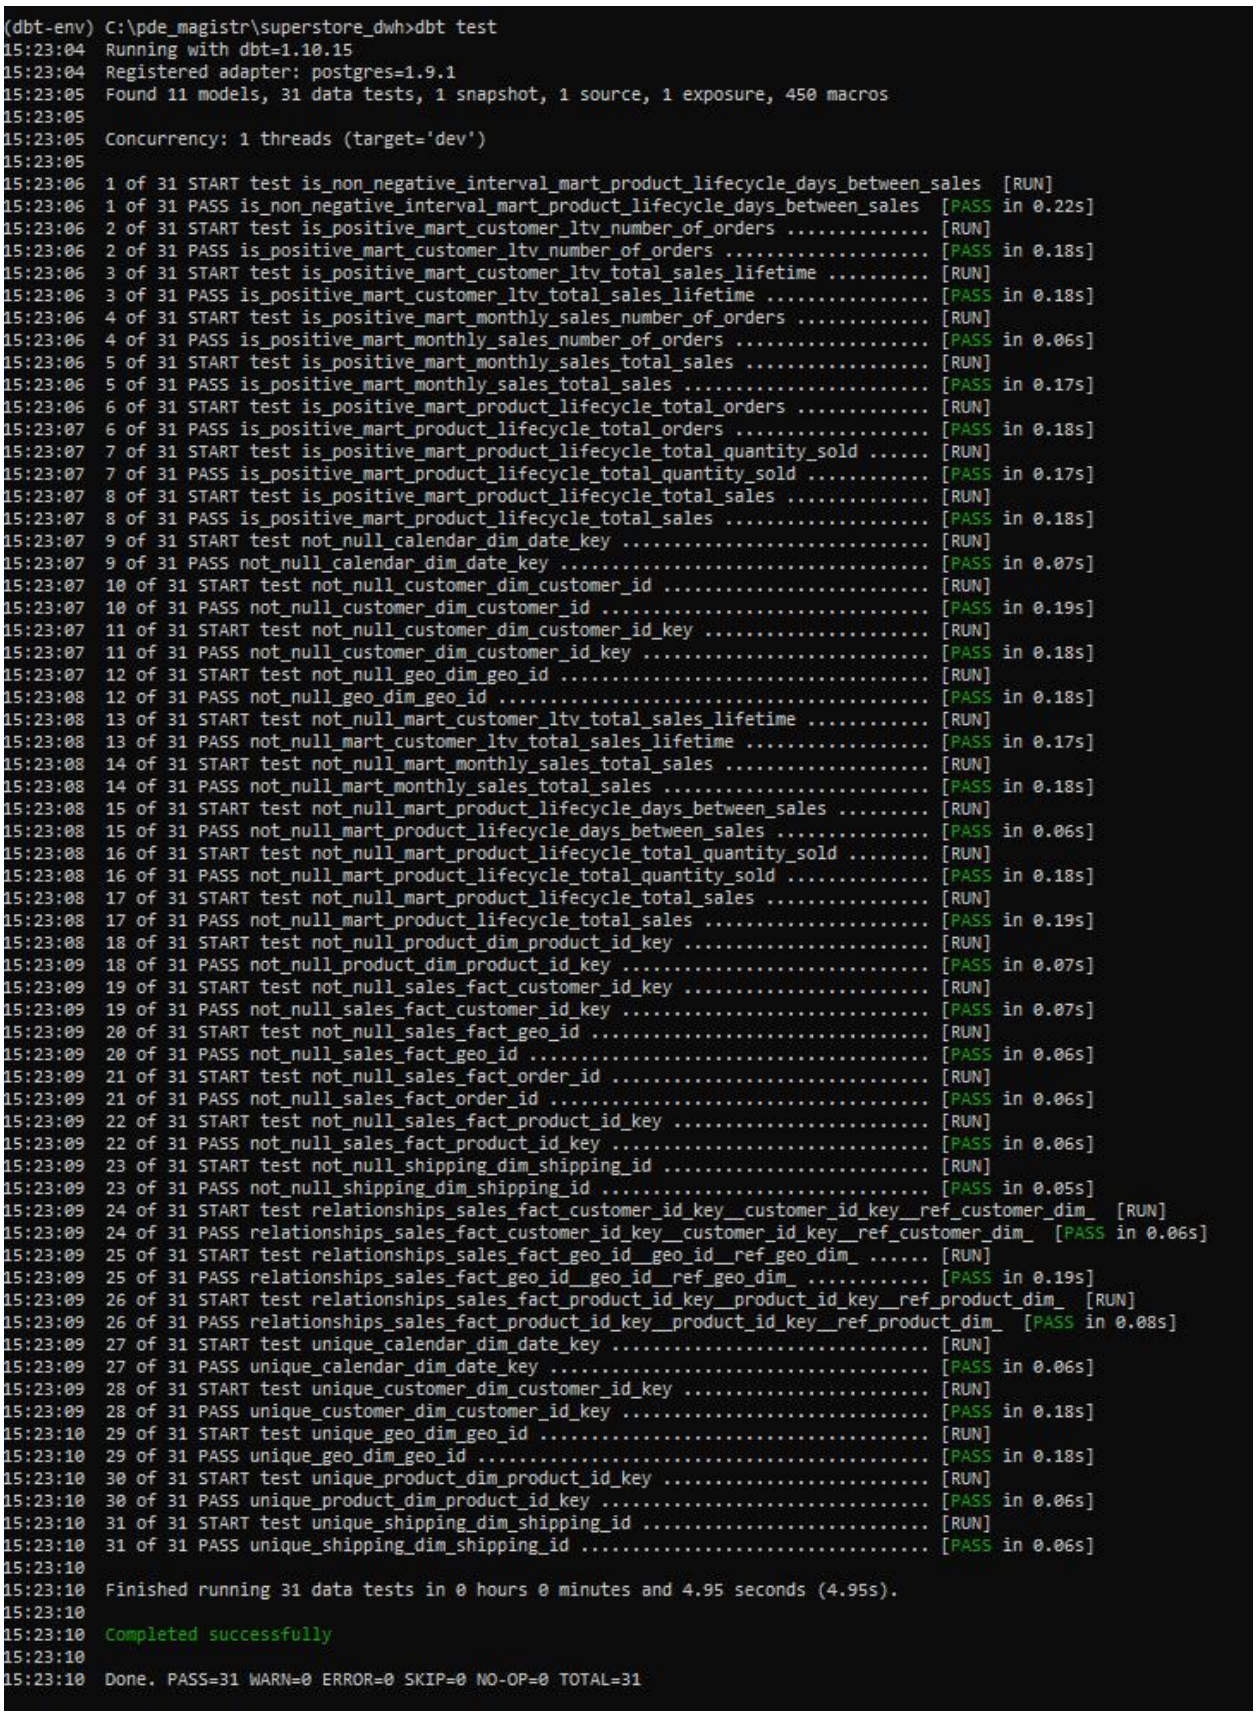

Скриншот выполнения dbt snapshot

```
(dbt-env) C:\pde_magistr\superstore_dwh>dbt snapshot
15:24:01  Running with dbt=1.10.15
15:24:01  Registered adapter: postgres=1.9.1
15:24:02  Found 11 models, 31 data tests, 1 snapshot, 1 source, 1 exposure, 450 macros
15:24:02
15:24:02  Concurrency: 1 threads (target='dev')
15:24:02
15:24:02  1 of 1 START snapshot dw_snapshots.snapshot_product_dim ..................... [RUN]
15:24:03  1 of 1 OK snapshotted dw_snapshots.snapshot_product_dim ..................... [SELECT 1894 in 0.17s]
15:24:03
15:24:03  Finished running 1 snapshot in 0 hours 0 minutes and 1.00 seconds (1.00s).
15:24:03
15:24:03  Completed successfully
15:24:03
15:24:03  Done. PASS=1 WARN=0 ERROR=0 SKIP=0 NO-OP=0 TOTAL=1

(dbt-env) C:\pde_magistr\superstore_dwh>
```

Скриншот данных из mart_product_lifecycle

```
Данные из mart_product_lifecycle:
================================================================================
                                                product_name        category subcategory first_sale_date last_sale_date days_between_sales  total_ord
ers  total_quantity_sold  total_sales
                                 Ibico Hi-Tech Manual Binding System Office Supplies     Binders      2014-01-06     2017-12-30          1454 days
14                119.0    17057.341
                                              GBC Binding covers Office Supplies     Binders      2014-01-06     2017-12-30          1454 days
14                119.0    17057.341
        Acco Four Pocket Poly Ring Binder with Label Holder, Smoke, 1" Office Supplies     Binders      2014-01-07     2017-12-24          1447 days
6                 76.0      350.150
                                                 Xerox 225 Office Supplies       Paper      2014-01-06     2017-12-10          1434 days
9                105.0      620.784
                                                Newell 327 Office Supplies         Art      2014-01-20     2017-12-21          1431 days
4                 69.0      152.490
                                    Memorex Micro Travel Drive 8 GB      Technology Accessories      2014-01-09     2017-12-07          1428 days
8                 66.0      743.600
                                        Avery Metallic Poly Binders Office Supplies     Binders      2014-01-13     2017-12-10          1427 days
6                 70.0      317.442
Acco Pressboard Covers with Storage Hooks, 9 1/2" x 11", Executive Red Office Supplies     Binders      2014-01-20     2017-12-17          1427 days
9                133.0      447.294
                           Rogers Handheld Barrel Pencil Sharpener Office Supplies         Art      2014-01-06     2017-12-02          1426 days
7                 84.0      215.364
                                               GE 30524EE4      Technology      Phones      2014-01-06     2017-12-02          1426 days
9                119.0    19481.406
================================================================================
Всего записей в таблице: 1894
```

Выводы

Преимущества использования промежуточных моделей и витрин:

1) Инкапсуляция бизнес-логики - сложные JOIN и преобразования вынесены в промежуточный слой, что предотвращает дублирование кода

2) Упрощение витрин - аналитические модели становятся простыми агрегациями над готовыми денормализованными данными

3) Повторное использование - одна промежуточная модель может использоваться в нескольких витринах

4) Облегчение тестирования - бизнес-логика тестируется в одном месте

5) Улучшение производительности - оптимизированные промежуточные модели ускоряют построение витрин

6) Специализация витрин - каждая витрина решает конкретную бизнес-задачу и содержит только необходимые данные

7) Упрощение сопровождения - изменения в бизнес-логике вносятся в одном месте (intermediate-модели)

8) Лучшая документация - четкое разделение ответственности между слоями улучшает понимание архитектуры

По сравнению с работой напрямую с единой таблицей фактов, предложенная архитектура обеспечивает лучшую масштабируемость, поддерживаемость и соответствие бизнес-потребностям.